

# Синтаксический анализ, часть II

## Нисходящий LL(1) разбор

Кирилл Юхин

МФТИ, 17 октября 2018 года

- Грамматика  $\langle N, \Sigma, P, S \rangle$
- Продукции ( $P$ )
  - ▶ Контекстно-зависимая:  $(\Sigma \cup N)^* N (\Sigma \cup N)^* \rightarrow (\Sigma \cup N)^*$
  - ▶ Контекстно-свободная:  $N \rightarrow (\Sigma \cup N)^*$
- Применение продукции
$$x \xRightarrow{G} y \iff \exists u, v, p, q \in (\Sigma \cup N)^* : (x = upv) \wedge (p \rightarrow q \in P) \wedge (y = uq)$$
- Нисходящий и восходящий разборы
- Сентенциальная форма — последовательность символов (терминалов и нетерминалов), выводимых из начального символа.  
Элемент множества  $\left\{ w \in (\Sigma \cup N)^* \mid S \xRightarrow{*}_G w \right\}$
- Язык, порождаемый грамматикой  $L(G) = \left\{ w \in \Sigma^* \mid S \xRightarrow{*}_G w \right\}$

# Алгоритм рекурсивного спуска

```
void A() {  
    // Select A-production  $A \rightarrow X_1 X_2 \dots X_k$   
    for (i = 1; i <= k; ++i) {  
        if ( $X_i$  – non terminal)  
             $X_i()$ ;  
        else if ( $X_i$  equal to current token a)  
            goto next input token;  
        else  
            report error;  
    }  
}
```

# Дерево вывода, сопоставления

- $[r]X \rightarrow \gamma$  - продукция  $r$  отображает нетерминал  $X$  на строку  $\gamma$
- $\omega : \gamma$  - строка терминалов  $\omega$  сопоставлена со строкой  $\gamma$

$$\frac{}{\epsilon : \epsilon} P_1$$

$$\frac{\omega_1 : \gamma_1 \quad \omega_2 : \gamma_2}{\omega_1 \omega_2 : \gamma_1 \gamma_2} P_2$$

$$\frac{}{a : a} P_3$$

$$\frac{[r]X \rightarrow \gamma \quad \omega : \gamma}{\omega : X} P_4(r)$$

## Пример дерева вывода

$$\begin{array}{c}
\frac{\overline{\quad} P_3 \quad \frac{\overline{\epsilon : \epsilon} P_1}{\overline{\epsilon : S} P_4(\text{emp})} \quad \frac{\overline{\quad} P_3}{[\ ] : [\ ]} \quad \overline{\quad} P_2^2}{\overline{\quad} P_2^2} \\
\frac{[\ ] : [S]}{[\ ] : S} P_4(\text{pars}) \quad \vdots \quad [\ ] : S \quad P_2}{[\ ] [\ ] : SS} P_4(\text{dup}) \\
\frac{\overline{\quad} P_3 \quad \frac{[\ ] [\ ] : SS}{[\ ] [\ ] : S} P_4(\text{dup}) \quad \overline{\quad} P_3}{\overline{\quad} P_2^2} \\
\frac{[\ ] [\ ] [\ ] : [S]}{[\ ] [\ ] [\ ] : S} P_4(\text{pars})
\end{array}$$

# Рекурсивный спуск

$$\frac{}{\epsilon : \epsilon} R_1$$

$$\frac{a\omega : a\gamma}{\omega : \gamma_2} R_2$$

$$\frac{[r]X \rightarrow \beta}{\omega : X\gamma} R_3(r)$$

# Пример рекурсивного спуска

	$\epsilon$	:	$\epsilon$	
	$;$	:	$;$	
	$id$	$;$	$id$	$;$
	$id$	$;$	$E$	$;$ [ident]
	return $id$	$;$	return $E$	$;$
	return $id$	$;$	$S$	[return]
	$;$	return $id$	$;$	$;$ $S$
	$num$	$;$	return $id$	$;$ $num$ $;$ $S$
	$num$	$;$	return $id$	$;$ $E$ $;$ $S$ [number]
	$=$ $num$	$;$	return $id$	$;$ $=$ $E$ $;$ $S$
	$id = num$	$;$	return $id$	$;$ $id = E$ $;$ $S$
	$id = num$	$;$	return $id$	$;$ $S$ [assign]

# Предиктивный анализатор

- Попытаемся построить синтаксический анализатор без откатов.
- Для каждого входного символа  $a$  и продукций  $A \rightarrow \alpha_1 \dots \alpha_n$  мы должны однозначно указать какая из них порождает строку начинающуюся с  $a$ .
- Управляющие конструкции языков программирования как правило позволяют это сделать:

```
stmt  $\rightarrow$  if expr then stmt else stmt  
      | while expr do stmt  
      | begin stmt_list end
```



# Основные понятия LL(1)

- $first(\beta, a)$  - терминал  $a$  может первым в слове, выведенном из  $\beta$
- $null(\beta)$  - из  $\beta$  можно вывести пустую строку

$$\frac{}{first(a\beta, a)} F_1$$

$$\frac{first(X, a)}{first(X\beta, a)} F_2$$

$$\frac{null(X) \quad first(\beta, a)}{first(X\beta, a)} F_3$$

$$\frac{[r]X \rightarrow \gamma \quad first(\gamma, a)}{first(X, a)} F_4(r)$$

$$\frac{}{null(\epsilon)} N_1$$

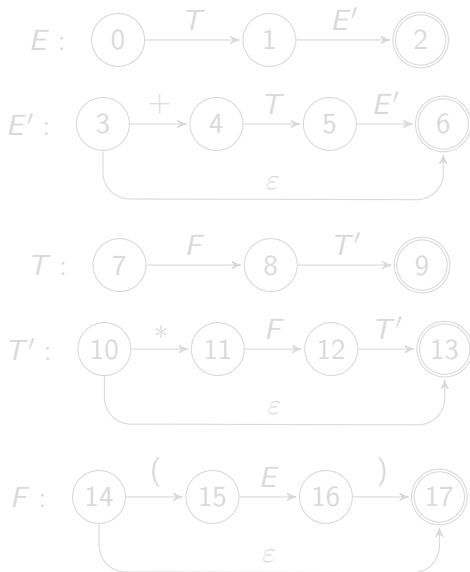
$$\frac{null(X) \quad null(\beta)}{null(X, \beta)} N_2$$

$$\frac{[r]X \rightarrow \gamma \quad null(\gamma)}{null(X)} N_3(r)$$

# Диаграмма переходов

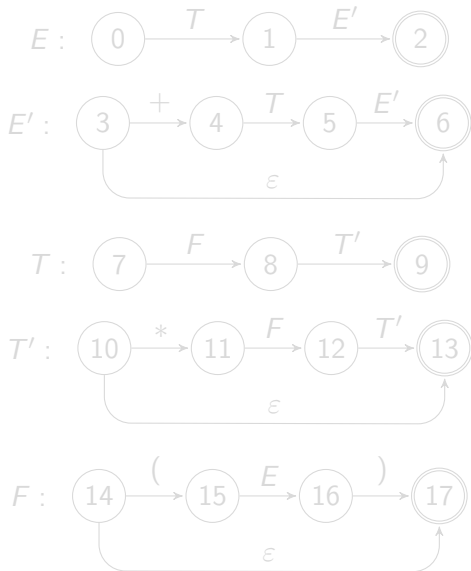
- Можно представить план предиктивного синтаксического анализатора в виде диаграммы переходов.
- Для каждого нетерминала - отдельная диаграмма переходов.
- Дуги двух типов:
  - 1 Терминалы - поглощение входного токена
  - 2 Нетерминалы - вызов процедуры нетерминала
- Построение:
  - 1 Для каждого нетерминала строим начальное и конечное состояние
  - 2 Для каждой продукции нетерминала  $A \rightarrow A_1 \dots A_n$  строим путь из начального состояния в конечное через дуги  $A_1 \dots A_n$

# Диаграмма переходов



$E \rightarrow E + T \mid T$   
 $T \rightarrow T * F \mid F$   
 $F \rightarrow (E) \mid \text{id}$

# Диаграмма переходов



$E \rightarrow TE'$




$E' \rightarrow +TE' \mid \epsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT' \mid \epsilon$

$F \rightarrow (E) \mid \text{id}$

# Диаграмма переходов



$E \rightarrow TE'$

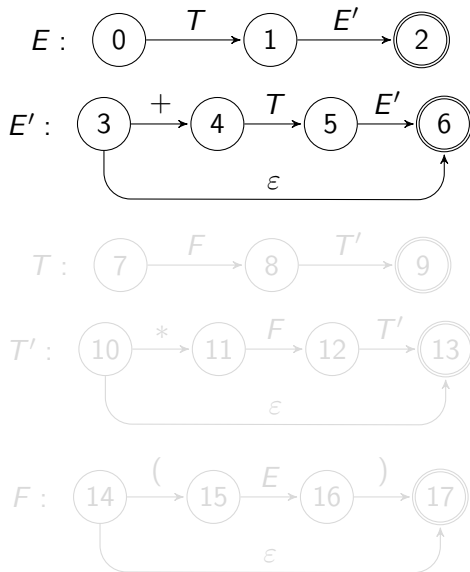
$E' \rightarrow +TE' \mid \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT' \mid \varepsilon$

$F \rightarrow (E) \mid \text{id}$

# Диаграмма переходов



$E \rightarrow TE'$

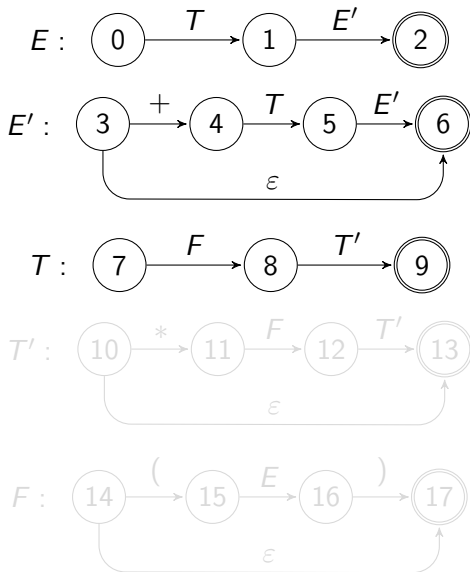
$E' \rightarrow +TE' \mid \epsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT' \mid \epsilon$

$F \rightarrow (E) \mid \text{id}$

# Диаграмма переходов



$$E \rightarrow TE'$$

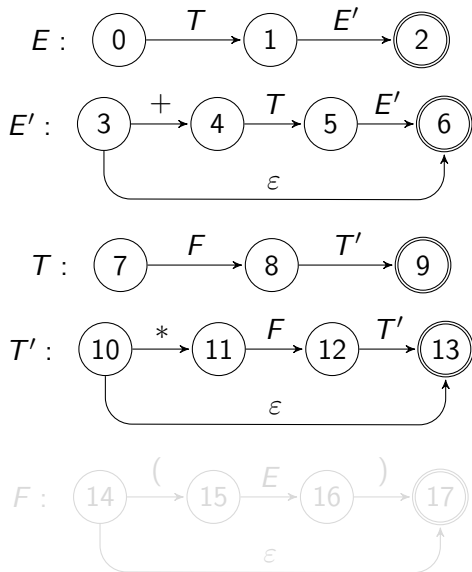
$$E' \rightarrow +TE' \mid \epsilon$$

$$T \rightarrow FT'$$

$$T' \rightarrow *FT' \mid \epsilon$$

$$F \rightarrow (E) \mid \text{id}$$

# Диаграмма переходов



$E \rightarrow TE'$

$E' \rightarrow +TE' \mid \epsilon$

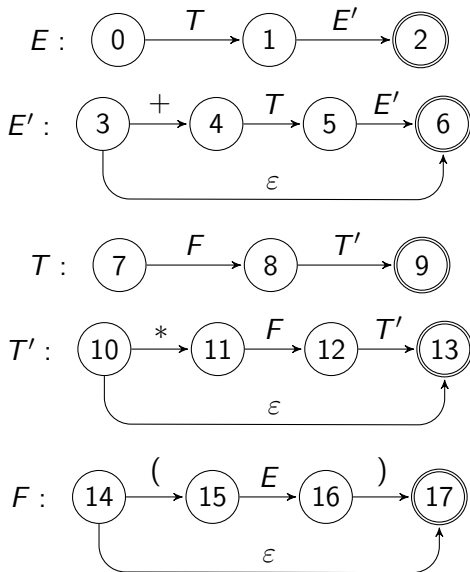
$T \rightarrow FT'$

$T' \rightarrow *FT' \mid \epsilon$

$F \rightarrow (E) \mid \text{id}$



## Диаграмма переходов



$$E \rightarrow TE'$$

$$E' \rightarrow +TE' \mid \epsilon$$

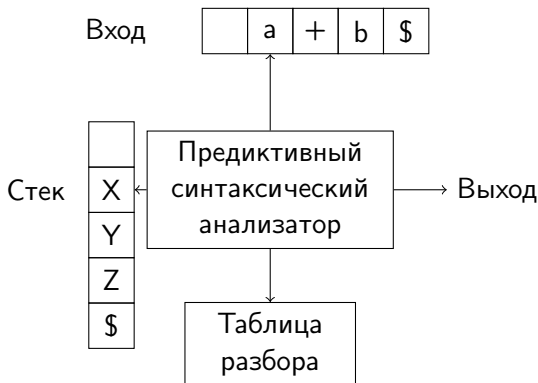
$$T \rightarrow FT'$$

$$T' \rightarrow *FT' \mid \epsilon$$

$$F \rightarrow (E) \mid \text{id}$$

# Нерекурсивный предиктивный анализ

- Неявное использование стека (в рекурсивном случае) можно заменить на явное.
- Предсказание следующей продукции по текущему нетерминалу и входному символу реализуем в виде поиска в таблице разбора



# Алгоритм

Установить указатель на  $ip$  на первый символ  $w$

**repeat**

Обозначим  $X$  - символ на вершине стека

$a$  - символ, на который указывает  $ip$

**if**  $X \in \{T, \$\}$  **then**

**if**  $X = a$  **then**

        Снять со стека  $X$  и переместить  $ip$

**else**

        Ошибка

**end if**

**else**

**if**  $M[X, a] = X \rightarrow Y_1 \dots Y_k$  **then**

        Снять  $X$  со стека

        Поместить в стек  $Y_k \dots Y_1$

**else**

        Ошибка

**end if**

**end if**

**until**  $X = \$$

# Пример таблицы

Нетерминал	Входной символ					
	id	+	*	(	)	\$
$E$	$E \rightarrow TE'$			$E \rightarrow TE'$		
$E'$		$E' \rightarrow +TE'$			$E' \rightarrow \varepsilon$	$E' \rightarrow \varepsilon$
$T$	$T \rightarrow FT'$			$T \rightarrow FT'$		
$T'$		$T' \rightarrow \varepsilon$	$T' \rightarrow *FT'$		$T' \rightarrow \varepsilon$	$T' \rightarrow \varepsilon$
$F$	$F \rightarrow \text{id}$			$F \rightarrow (E)$		

# Множества FIRST и FOLLOW

**FIRST** Если  $\alpha$  - произвольная строка символов грамматики, то определим  $FIRST(\alpha)$  как множество терминалов, с которых начинаются строки, выводимые из  $\alpha$

- Если  $\alpha \xrightarrow{*} \varepsilon$ , то  $\varepsilon \in FIRST(\alpha)$

**FOLLOW** Определим множество  $FOLLOW(A)$  для нетерминала  $A$ , как множество терминалов  $a$ , которые могут располагаться непосредственно справа от  $A$  в некоторой сентенциальной форме<sup>1</sup>.

- $FOLLOW(A) = \{a \in T \mid \exists \alpha, \beta : \exists S \xrightarrow{*} \alpha A a \beta\}$
- Если  $A$  может оказаться крайним справа символом некоторой сентенциальной формы, то  $\$ \in FOLLOW(A)$

---

<sup>1</sup>Сентенциальная форма — последовательность символов (терминалов и нетерминалов), выводимых из начального символа

# Построение FIRST

- Если  $X$  - терминал, то  $FIRST(X) = X$ .
- Если имеется продукция  $X \rightarrow \varepsilon$ , добавим  $\varepsilon$  к  $FIRST(X)$ .
- Если  $X$  - нетерминал и имеется продукция  $X \rightarrow Y_1 \dots Y_k$ , то поместим  $a$  в  $FIRST(X)$ , если для некоторого  $i$   $a \in FIRST(Y_i)$  и  $\varepsilon \in \{FIRST(Y_1) \cup \dots \cup FIRST(Y_{i-1})\}$ , т.е.  $Y_1 \dots Y_{i-1} \xrightarrow{*} \varepsilon$ .
- Если  $\varepsilon \in \{Y_1 \cap \dots \cap Y_k\}$ , то добавляем  $\varepsilon$  в  $FIRST(X)$ .

# Построение FOLLOW

- Поместим  $\$$  в  $FOLLOW(S)$ , где  $S$  - стартовый символ, а  $\$$  - маркер конца строки.
- Если имеется продукция  $A \rightarrow \alpha B \beta$ , то все элементы  $FIRST(\beta)$ , кроме  $\varepsilon$ , помещаются в множество  $FOLLOW(B)$ .
- Если имеется продукция  $A \rightarrow \alpha B$  или  $A \rightarrow \alpha B \beta$ , где  $FIRST(\beta)$  содержит  $\varepsilon$  (т.е.  $\beta \xrightarrow{*} \varepsilon$ ), то все элементы из множества  $FOLLOW(A)$ , помещаются в множество  $FOLLOW(B)$ .

# Построение таблицы переходов

- Строим FIRST и FOLLOW
- Для каждой продукции грамматики  $A \rightarrow \alpha$ :
  - ▶ Для каждого терминала  $a$  из  $FIRST(\alpha)$  добавляем  $A \rightarrow \alpha$  в ячейку  $M[A, a]$ .
  - ▶ Если  $\varepsilon \in FIRST(\alpha)$ , то для каждого терминала  $b$  из  $FOLLOW(A)$  добавим  $A \rightarrow \alpha$  в ячейку  $M[A, b]$ .
  - ▶ Если  $\varepsilon \in FIRST(\alpha)$ , а  $\$ \in FOLLOW(A)$ , добавим  $A \rightarrow \alpha$  в ячейку  $M[A, ]$ .
- Пустые ячейки делаем указывающими на ошибку.



# LL(1) грамматики

- Построенная таблица может иметь несколько записей в одной ячейке.
  - ▶ Левая рекурсия
  - ▶ Неоднозначность
- Грамматика, таблица которой не имеет множественных записей называется LL(1)
  - ▶ L - слева-направо
  - ▶ L - левое порождение
  - ▶ 1 - один символ для предсказания